

Nama: Akbar Fitri Andhika

NIM: 2410511011

Kelas: Informatika (A)

Dataset

Dataset yang digunakan dalam proyek ini adalah Wine Dataset yang tersedia secara bawaan pada library scikit-learn. Dataset ini merupakan hasil analisis kimia terhadap sampel wine yang berasal dari tiga jenis kultivar (varietas tanaman anggur) berbeda yang tumbuh di wilayah Italia. Dataset ini terdiri dari 178 sampel data dengan 13 fitur numerik sebagai variabel masukan, yaitu:

1. Alcohol : kadar alkohol dalam wine
2. Malic Acid : kadar asam malat
3. Ash : kadar abu
4. Alcalinity of Ash : alkalinitas abu
5. Magnesium : kadar magnesium
6. Total Phenols : total fenol
7. Flavanoids : kadar flavanoid
8. Nonflavanoid Phenols : fenol non-flavanoid
9. Proanthocyanins : kadar proantosianin
10. Color Intensity : intensitas warna
11. Hue : tingkat kejernihan warna (hue)
12. OD280/OD315 of Diluted Wines : rasio absorbansi optik
13. Proline : kadar prolin

Variabel target (label) terdiri dari 3 kelas, yang merepresentasikan tiga jenis kultivar wine berbeda, yaitu Kelas 1 (Wine A), Kelas 2 (Wine B), dan Kelas 3 (Wine C). Dataset ini bersifat publik, bersih (tidak terdapat nilai yang hilang), dan sudah banyak digunakan sebagai benchmark dalam penelitian klasifikasi multikelas.

Pembagian Data

Data dibagi menjadi dua bagian menggunakan fungsi `train_test_split` dari scikit-learn dengan proporsi sebagai berikut:

- Data Latih (Training Set): 80% dari total data, digunakan untuk melatih model

- Data Uji (Testing Set): 20% dari total data, digunakan untuk mengevaluasi performa model

Parameter `random_state=42` digunakan untuk memastikan pembagian data bersifat deterministik dan dapat direproduksi.

Prapemrosesan Data

Sebelum proses pelatihan, seluruh fitur dinormalisasi menggunakan `StandardScaler` dari `scikit-learn`. `StandardScaler` bekerja dengan cara mengubah setiap fitur sehingga memiliki rata-rata (mean) senilai 0 dan standar deviasi senilai 1. Proses ini diperlukan karena algoritma Logistic Regression sensitif terhadap skala fitur yang berbeda-beda.

Objek normalisasi disimpan ke dalam file `normalisasi.pkl` menggunakan `joblib` agar dapat dimuat kembali saat proses inferensi (prediksi), sehingga data masukan baru akan dinormalisasi secara konsisten dengan data latih.

Model

Model yang digunakan adalah Logistic Regression (Regresi Logistik), salah satu algoritma klasifikasi yang umum digunakan untuk masalah klasifikasi multikelas. Meskipun namanya mengandung kata "regresi", algoritma ini digunakan untuk tugas klasifikasi. Konfigurasi model yang digunakan adalah sebagai berikut:

- `max_iter=200` : jumlah iterasi maksimum selama proses optimasi, ditingkatkan dari nilai default (100) untuk memastikan model dapat konvergen
- `random_state=42` : untuk memastikan hasil pelatihan yang konsisten dan dapat direproduksi

Model bekerja dengan cara mempelajari batas keputusan (decision boundary) antarkelas berdasarkan kombinasi linear dari fitur-fitur yang diberikan, kemudian menggunakan fungsi softmax untuk menghasilkan probabilitas keanggotaan terhadap masing-masing kelas.

Evaluasi Model

Berdasarkan hasil evaluasi pada data uji, model mencapai akurasi sebesar 100%, yang berarti seluruh sampel pada data uji berhasil diklasifikasikan dengan benar. Performa ini dimungkinkan karena dataset Wine memiliki karakteristik yang cukup terpisah antarkelasnya, sehingga Logistic Regression mampu menemukan batas keputusan yang optimal setelah normalisasi data.

Model yang telah dilatih disimpan ke dalam file `model.pkl` menggunakan `joblib` dan dimuat secara otomatis saat layanan Flask dijalankan.